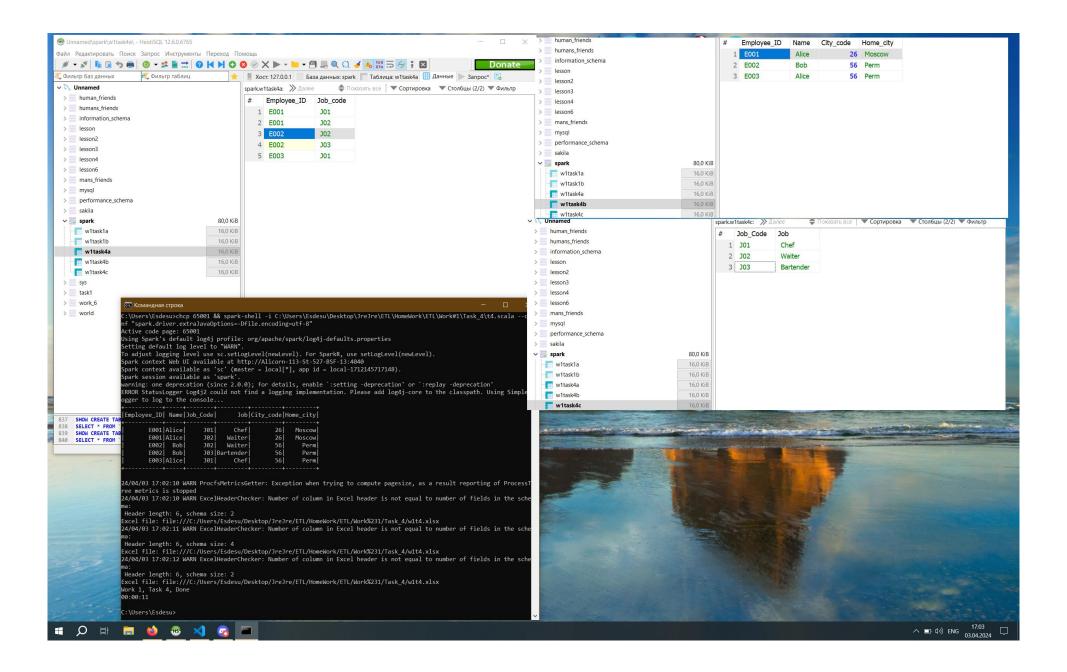
4. Определите в какой нормальной форме данная таблица, приведите ее ко 2 и 3 нормальным формам последовательно. Нужно в apache spark создать таблицу сданными ниже. Можно импортировать из Excel либо с генерировать ее кодом.

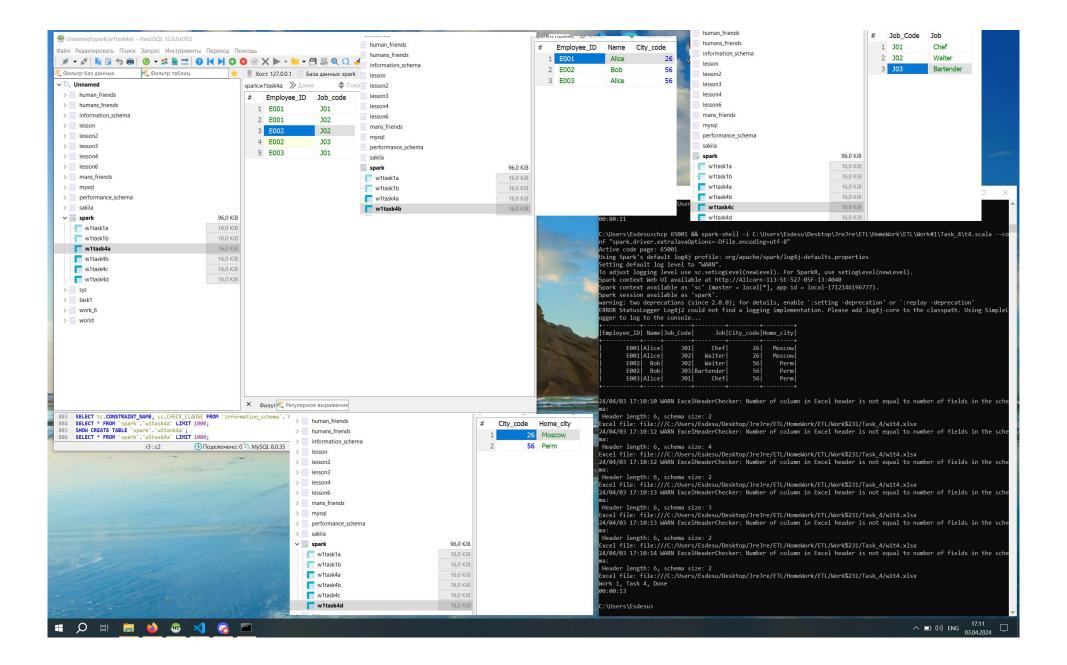
Сделать нормализацию по образцу

Сохранить полученный результат в БД. На проверку соберите код, скриншоты отработки консоли спарка и полученный результат в БД в один pdf файл.

Employee_ID	Name	Job_Code	Job	City_code	Home_city
E001	Alice	J 01	Chef	26	Moscow
E001	Alice	Ј02	Waiter	26	Moscow
E002	Bob	Ј02	Waiter	56	Perm
E002	Bob	J03	Bartender	56	Perm
E003	Alice	J 01	Chef	56	Perm

Представленная таблица находится в форме NF1, далее переводим её к NF2 и NF3 последовательно.





```
chcp 65001 && spark-shell -i C:\Users\Esdesu\Desktop\JreJre\ETL\HomeWork\ETL\Work#1\Task_4\t4.scala --conf
 spark.driver.extraJavaOptions=-Dfile.encoding=utf-8"
import org.apache.spark.internal.Logging
import org.apache.spark.sql.functions.{col, collect list, concat ws}
import org.apache.spark.sql.{DataFrame, SparkSession}
import org.apache.spark.sql.expressions.Window
val t1 = System.currentTimeMillis()
val sqlCoun = "jdbc:mysql://localhost:3306/spark?user=root&password="
val driver = "com.mysql.cj.jdbc.Driver"
if(1==1){
   var df1 = spark.read.format("com.crealytics.spark.excel")
            .option("sheetName", "Sheet1")
            .option("useHeader", "false")
            .option("treatEmptyValuesAsNulls", "false")
            .option("inferSchema", "true").option("addColorColumns", "true")
            .option("usePlainNumberFormat","true")
            .option("startColumn", 0)
            .option("endColumn", 99)
            .option("timestampFormat", "MM-dd-yyyy HH:mm:ss")
            .option("maxRowsInMemory", 20)
            .option("excerptSize", 10)
            .option("header", "true")
            .format("excel")
            .load("C:/Users/Esdesu/Desktop/JreJre/ETL/HomeWork/ETL/Work#1/Task 4/w1t4.xlsx")
           df1.show()
            df1.filter(col("Employee ID").isNotNull).select("Employee ID", "Job code")
```

```
.write.format("jdbc").option("url", sqlCoun)
            .option("driver", driver).option("dbtable", "w1task4a")
            .mode("overwrite").save()
           val nf2 = Window.partitionBy(lit(1)).orderBy(("id")).rowsBetween(Window.unboundedPreceding, Window.currentRow)
           val df2 = df1.withColumn("id", monotonicallyIncreasingId())
           df2.withColumn("Employee_ID", when(col("Employee_ID").isNull, last("Employee_ID", ignoreNulls =
true).over(nf2)).otherwise(col("Employee_ID")))
            .withColumn("table", lit("w1task4b"))
            .orderBy("id").drop("id", "Job_Code", "Job")
            .filter(col("table") === "w1task4b")
            .dropDuplicates()
            .drop("table")
            .write.format("jdbc").option("url", sqlCoun)
            .option("driver", driver).option("dbtable", "w1task4b")
            .mode("overwrite").save()
           df2.withColumn("table", lit("w1task4c"))
            .orderBy("id").drop("id", "Employee ID", "Name", "City code", "Home city")
            .filter(col("table") === "w1task4c")
            .dropDuplicates()
            .drop("table")
            .write.format("jdbc").option("url", sqlCoun)
            .option("driver", driver).option("dbtable", "w1task4c")
            .mode("overwrite").save()
           val nf3 = Window.partitionBy(lit(1)).orderBy(("id")).rowsBetween(Window.unboundedPreceding, Window.currentRow)
            val df3 = df1.withColumn("id", monotonicallyIncreasingId())
```

```
df3.withColumn("Employee_ID", when(col("Employee_ID").isNull, last("Employee_ID", ignoreNulls =
true).over(nf2)).otherwise(col("Employee_ID")))
            .withColumn("table", lit("w1task4b"))
            .orderBy("id").drop("id", "Job_Code", "Job", "Home_city")
            .filter(col("table") === "w1task4b")
            .dropDuplicates()
            .drop("table")
            .write.format("jdbc").option("url", sqlCoun)
            .option("driver", driver).option("dbtable", "w1task4b")
            .mode("overwrite").save()
           df3.withColumn("table", lit("w1task4c"))
            .orderBy("id").drop("id", "Employee_ID", "Name", "City_code", "Home_city")
            .filter(col("table") === "w1task4c")
            .dropDuplicates()
            .drop("table")
            .write.format("jdbc").option("url", sqlCoun)
            .option("driver", driver).option("dbtable", "w1task4c")
            .mode("overwrite").save()
           df3.withColumn("table", lit("w1task4d"))
            .orderBy("id").drop("id", "Employee_ID", "Name", "Job_Code", "Job")
            .filter(col("table") === "w1task4d")
            .dropDuplicates()
            .drop("table")
            .write.format("jdbc").option("url", sqlCoun)
            .option("driver", driver).option("dbtable", "w1task4d")
            .mode("overwrite").save()
            println("Work 1, Task 4, Done")
```

```
val s0 = (System.currentTimeMillis() - t1)/1000
val s = s0 % 60
val m = (s0/60) % 60
val h = (s0/60/60) % 24
println("%02d:%02d".format(h, m, s))
System.exit(0)
```